

Лабораторная работа №5

«Лексический распознаватель»

Скоробогатов С. Ю., Коновалов А. В.

29 марта 2016

1 Цель работы

Целью данной работы является изучение использования детерминированных конечных автоматов с размеченными заключительными состояниями (лексических распознавателей) для решения задачи лексического анализа.

2 Исходные данные

Пусть лексическая структура модельного языка состоит из шести лексических доменов:

1. пробелы — непустые последовательности пробельных символов (пробел, горизонтальная табуляция, маркеры конца строки);
2. идентификаторы — непустые последовательности латинских букв и десятичных цифр, начинающиеся с буквы;
3. целочисленные литералы — непустые последовательности десятичных цифр;
4. ключевые слова (варианты ключевых слов перечислены в таблицах 1 и 2);
5. знаки операций (варианты знаков операций перечислены в таблицах 1 и 2);
6. комментарии или строковые литералы (варианты перечислены в таблицах 1 и 2).

Чтобы не усложнять лексический анализатор, разрешим идентификаторам примыкать справа к целочисленным литералам.

3 Задание

Выполнение лабораторной работы состоит из пяти этапов:

1. описание лексических доменов модельного языка в виде регулярных выражений;
2. построение недетерминированного лексического распознавателя для модельного языка;
3. детерминизация построенного лексического распознавателя и факторизация его алфавита;

4. построение массива обобщённых символов, матрицы переходов и массива заключительных состояний для полученного детерминированного лексического распознавателя с факторизованным алфавитом;
5. разработка лексического анализатора, работающего на основе интерпретации построенных структур данных.

Входной поток для лексического анализатора должен загружаться из файла (в ASCII). В результате работы программы в стандартный поток вывода должны выдаваться описания распознанных лексем в формате

Тег (координаты_фрагмента): изображение_лексемы

При этом лексемы, принадлежащие домену пробелов, должны отбрасываться.

Входной файл может содержать ошибки, при обнаружении которых лексический анализатор должен выдавать сообщение с указанием координаты, восстанавливаться и продолжать работу.

В лабораторной работе разрешается использовать любой язык программирования, поддерживающий массивы с операцией доступа к элементу по индексу, работающей за константное время.

1.

Таблица 1: Наборы ключевых слов и знаков операций по вариантам

1	if, then, else, (,), комментарии ограничены знаками {, } могут пересекать границы строк текста.
2	do, while, <, >, <> , строковые литералы ограничены апострофами, не могут пересекать границы строк текста.
3	begin, end, >, >= , комментарии начинаются со знака # и продолжаются до конца строки.
4	for, range, ==, != , строковые литералы ограничены двойными кавычками, не могут пересекать границы строк текста.
5	while, wend, <, <= , комментарии начинаются со знака -- и продолжаются до конца строки.
6	if, fi, do, od, {, } , строковые литералы ограничены обратными кавычками, могут пересекать границы строк текста.
7	case, break, +, ++ , комментарии ограничены знаками (*, *) могут пересекать границы строк текста.
8	class, super, -, -> , строковые литералы ограничены двойными кавычками, могут содержать escape-последовательности вида \x , где x — любой символ, не могут пересекать границы строк текста.
9	struct, type, =, == , комментарии начинаются с // и продолжаются до конца строки.
10	def, val, var, [,] , строковые литералы ограничены одинарными кавычками, для включения одинарной кавычки в строку она удваивается, не могут пересекать границы строк текста.
11	int, float, <, << , комментарии ограничены знаками @ , могут пересекать границы строк текста.
12	fun, let, in, :, :: , строковые литералы ограничены обратными кавычками, могут содержать escape-последовательности \n, \\, \' (остальные недопустимы), не могут пересекать границы строк текста.
13	select, from, :), : (, комментарии ограничены знаками [и] , не могут пересекать границы строк текста.
14	ford, forward, &&, , строковые литералы ограничены двойными кавычками, для включения кавычки в строковой литерал она предваряется знаком «\» (но знак «\» без последующей кавычки ошибкой не является), могут пересекать границы строк текста.
15	real, longreal, >=, := , комментарии начинаются с :: и продолжаются до конца строки.

Таблица 2: Наборы ключевых слов и знаков операций по вариантам

16	<code>uint8t</code> , <code>uint128t</code> , <code>(*, *)</code> , строковые литералы ограничены знаками <code>/</code> , допустимы escape-последовательности вида <code>\x</code> , где <code>x</code> — любой символ, могут пересекать границы строк текста.
17	<code>goto</code> , <code>gosub</code> , <code>\(, \)</code> , комментарии начинаются с <code>\\</code> и заканчиваются в конце строки.
18	<code>delete</code> , <code>decltype</code> , <code>-></code> , <code><-</code> , строковые литералы ограничены апострофами, могут пересекать границы строк текста, для включения апострофа внутрь строки он удваивается.
19	<code>if</code> , <code>elif</code> , <code>*</code> , <code>/</code> , комментарии ограничены знаками <code>/*, */</code> могут пересекать границы строк текста.
20	<code>lambda</code> , <code>quote</code> , <code>+</code> , <code>=</code> , <code>+=</code> , строковые литералы ограничены двойными кавычками, не могут пересекать границы строк текста.
21	<code>get</code> , <code>set</code> , <code> </code> , <code>+</code> , комментарии начинаются с <code> +</code> и заканчиваются на <code>+ </code> , могут пересекать границы строк текста, последовательность знаков <code> +</code> внутри комментария является синтаксической ошибкой.
22	<code>signed</code> , <code>unsigned</code> , <code>.</code> , <code>...</code> , строковые литералы ограничены запятыми, могут пересекать границы строк текста.
23	<code>plus</code> , <code>minus</code> , <code>>=</code> , <code><=</code> , <code>==</code> , комментарии начинаются с апострофа и продолжаются до конца строки.
24	<code>eq</code> , <code>neq</code> , <code>+-</code> , <code>-+</code> , строковые литералы ограничены знаками <code>:</code> , для включения двоеточия в строку оно удваивается, не могут пересекать границы строк текста.
25	<code>key</code> , <code>val</code> , <code>~~</code> , комментарии ограничены знаками <code>~</code> , могут пересекать границы строк текста.
26	<code>write</code> , <code>read</code> , <code>^_</code> , <code>^__</code> , строковые литералы ограничены двойными кавычками, кавычку в конце строки допустимо не ставить.
27	<code>exit</code> , <code>exist</code> , <code>!</code> , <code>!~</code> , комментарии начинаются со знака <code>~</code> и продолжаются до конца строки.
28	<code>set</code> , <code>unset</code> , <code>()</code> , строковые литералы начинаются с <code>(</code> , заканчиваются на <code>)</code> , не могут содержать внутри круглые скобки и не могут пересекать границы строк текста.
29	<code>ax</code> , <code>eax</code> , <code>rax</code> , <code>[,]</code> , комментарии начинаются со знака <code>;</code> или <code>#</code> и продолжаются до конца строки.